Аудит выполнения требований OilAgent

1 ноября 2026. Проверены core b1d2fa5 и evolution 4b829d0.

Вывод: работающий интеграционный прототип, но требования DOCX и целевая архитектура закрыты не полностью. Главные пробелы задания — комбинированный report+web ответ, сценарный расчёт, пять демонстрационных диалогов, воспроизводимый запуск всей системы одной командой. Самоулучшение пока не изменяет реальный retrieval.

Источники требований: оригинальный DOCX и ARCHITECTURE.md. Копия DOCX в docs побайтово совпадает с оригиналом в корне workspace. Архитектура содержит дополнительные предложения, а не только требования работодателя. Применён навык agent-architecture; аудит не меняет код или runtime settings.

1. Что проверено сейчас

- pytest -q: **103 passed**, 5 предупреждений сторонних библиотек.

- ruff check src scripts tests и ruff format --check src scripts tests: успешно.

- scripts/eval_reports.py --split holdout с отключённой сетью Hugging Face: **4/9** случаев с нужными фрагментами в retrieval и в контексте. Это не answer accuracy; результаты совпали с сохранённой оценкой.

- Две небольшие offline-пробы воспроизвели замену report evidence при web-fallback и статус answered после удаления части claims. Подменены внешние вызовы, не транспорт; это не live-проверка модели. Доказательства.

- docker compose config --quiet: успешно. docker info: daemon недоступен. Build/startup не проверены.

- В обоих локальных Git нет настроенного remote; URL опубликованного проекта не подтверждён.

- Live GigaChat, web, браузер и forecast повторно не запускались. Использованы ранее сохранённые evidence. **Новых LLM-вызовов: 0.**

Успех unit-тестов не доказывает качество аналитики, надёжность web, корректность финального пересказа UI или isolation. Исходные файлы и тесты просмотрены непосредственно; одних отметок в INTEGRATION_STATUS недостаточно.

2. Оригинальное задание DOCX

Требование	Фактическое состояние	Остаток / проверка закрытия
§1, §3: использовать Ouroboros и LangChain/ LangGraph	Реализовано: pinned Ouroboros, UI → Main → HTTP MCP → общий graph; есть live evidence	Не считать это завершённым циклом самоулучшения. Проверен адаптированный запуск с двумя in-process wrappers
§2.1: роль, отрасли, стиль, неопределённость	Роль подробно задана в instruction skill; core требует факты и цитаты, умеет воздерживаться	Нет оценки качества по Upstream/Midstream/ Downstream, WTI/Urals, санкциям и ОПЕК+; текущие live-примеры узкие
§2.2: чанки, metadata, embeddings, vector DB, top-k	Реализовано: PyMuPDF, E5, Chroma, источник/ дата/PDF page; локальные тесты и реальный корпус	Найденные фрагменты покрывают 4/9 отложенных вопросов; пять промахов открыты. Это ограничение качества, не отсутствие RAG
§2.3: web-поиск с фильтрацией СМИ	DDGS/DuckDuckGo, allowlist committed main evolution, даты и snippets; offline-тесты	Есть сохранённая выдача backend и ошибки adapter. Успешный свежий ответ через весь graph/UI не подтверждён
§2.3: текущие котировки	Не реализован надёжный live feed с instrument/ type/timestamp/unit; система честно ограничивает ответ	Показать текущую цену из подходящего источника либо явно согласовать ограничение сдачи. Не подменять её последней EIA spot observation
§2.4: RAG как основной источник, web как дополнение	Частично: исторические вопросы идут в RAG, свежие — сразу в web; fallback есть	Настоящее объединение report+web отсутствует: web-node заменяет evidence. Нужен ответ с обеими группами источников, датами и без потери подтверждённых report facts

§2.4: маркировка происхождения фактов	Core формирует report/web ссылки программно	Native Main уже ошибочно назвал дневную историю ежемесячным отчётом. Нужна проверка финального UI-ответа, а не только core JSON
§2.5: исторические цены, ≥2 метода, интервалы, самостоятельный вызов	Реализовано: ARIMA + ETS, naive benchmark, 80% интервалы, rolling calibration/test, явный срез; live MCP/Giga evidence	Номинальные 80% не означают фактические 80%: ETS coverage ранее около 38–69%; naive немного лучше. Это раскрытое ограничение модели, не скрытая подмена
§2.5: оценка диапазона при сокращении добычи на N	Не реализовано: intent scenario возвращает tool_unavailable	Добавить сценарный tool с явными inputs/допущениями, единицами и диапазоном, а без inputs — уточнение; ARIMA без факторов этот сценарий не заменяет
§3: Python 3.10+, LangChain/LangGraph	Реализовано и проверено на Python 3.13/macOS ARM64	Python 3.10/3.11 и Linux не проверены; минимальная версия самого проекта заявлена 3.11. Требование «3.10+» не означает обязательную поддержку всех версий
§3: LLM и объяснение выбора в README	GigaChat выбран и реально проверен; openai/local поддержаны кодом и offline-тестами	В README есть настройка, но нет чёткого обоснования выбора GigaChat. Живые openai/local и их structured output не проверены
§3: простой UI	Используется согласованный native UI Ouroboros; реальные браузерные report/forecast пробы	Частичная приёмка: источник forecast пересказан неверно; web/hybrid/out-of-scope/follow-up диалоги через UI не подтверждены
§3: Dockerfile и запуск одной командой	Есть Dockerfile и compose для двух MCP	UI/runtime/bootstrap/indexing не входят в compose; clean full-system startup одной командой отсутствует. Daemon недоступен, build/run не проверены
§3: конфигурация через .env, пример	Ключи, провайдеры, пути, top-k, timeout и output limit вынесены; есть .env.example	Размеры evidence, freshness 7 дней, некоторые параметры моделей и native limits заданы в коде. Нет единой полной конфигурации и подтверждённого переноса CA/путей в Docker
§4.1: GitHub/GitLab с чистой структурой	Два независимых соседних Git, исходники закоммичены	Публикация/URL не подтверждены; remote не настроен. Аудит не публикует проект
§4.2–4.3: исходники RAG/forecast, PDFs или загрузчик	Реализовано: исходники, manifest hashes, скрипт загрузки и индексирования; daily CSV в Git	Чистую установку на новой машине надо проверить отдельно; локальный подготовленный workspace этого не доказывает
§4.4: README, архитектура, запуск, запросы	Есть, примеры report/forecast и команды запуска присутствуют	Инструкции многошаговые; требуют проверки с нуля, синхронизации с фактической поставкой и объяснения выбора модели
§4.5: краткий отчёт 1–2 страницы с решениями/ограничениями	Есть старые ARCHITECTURE_SUMMARY.md/PDF, явно помеченные «до реализации»	Нужен итоговый отчёт о фактической реализации. Старый summary описывает Streamlit и ещё не исполненные компоненты; текущий аудит его не заменяет
§4.6: минимум 5 диалогов: report/web/hybrid/forecast/out-of-scope	Полного набора нет; есть отдельные evidence report/forecast и неуспех web	Добавить реальные диалоги и traces для всех пяти типов. Файла examples/demo_dialogues.md нет; вопросы и synthetic тесты не равны демонстрационным диалогам

3. Дополнительные обещания ARCHITECTURE.md

Раздел	Фактический пробел	Что уже есть / критерий закрытия
§4: сессионная память	Core принимает только question, не хранит session_id, последние 6 сообщений или структурированные сущности	История есть у native UI, skill просит разрешать follow-up. Это не реализация описанного core-контракта; проверить «а теперь на полгода?», неоднозначность и изоляцию сессий

§4: typed routing с сущностями и периодами	Route содержит intent/freshness/horizon/as_of/instrument/start/end, но нет metric/geography/publishers/reference_period или уточняемых сущностей	Нужен полный контракт либо честное сокращение документа; не менять текст ради скрытия обязательного поведения
§4, §6: достаточность и partial	Достаточность определяется в основном наличием принятых claims; нет покрытия частей запроса	Offline-проба: из 2 claims один удалён как invalid_citation, статус всё равно answered. Нужны проверка полноты и явные пробелы
§4: один repair и шаблонный fallback	Отдельного repair нет; существует только один web-fallback после insufficient_evidence	Проверить невалидный синтез → один repair → понятный partial, без циклов и придуманных данных
§5: сравнение показателей	Нет нормализации metric/geography/unit/period/vintage/actual-vs-forecast, защищённого вычисления разности	Есть interleave издателей и запрет LLM самостоятельно считать. Это помогает retrieval, но не реализует сравнение по контракту
§5: корпус/ingestion	Есть OPEC+EIA, IEA summary отсутствует; metadata reference_period/language/material_type/extraction_status неполны	IEA в архитектуре условен доступностью и не обязателен DOCX. Atomic index pointer реализован; полноценное извлечение/сравнение vintages не доказано
§6: typed claims	Есть text/source_id/quote и проверки подстроки/чисел	Нет типов fact/calculation/assumption, явных unit/period/value, формул/inputs/tool-run-id и проверки простой арифметики
§6, §10: смысловая достоверность	Exact quote и совпадение чисел не проверяют смысл, единицы и принадлежность факта вопросу	Нужна ручная claim→span→источник rubric на нескольких типах вопросов. Нулевые галлюцинации не обещаются
§8: реально исполняемая retrieval-policy	Policy читается и исполняется в synthetic checks, но ReportIndex.search её не загружает	До/после одной policy должны менять настоящий serving retrieval, на одном frozen корпусе и без подмены baseline
§8: paired evaluation и hidden holdout	Checks — три синтетические строки A1/A2/B1, не сравнение ответов на PDF-корпусе	Есть отдельная developer retrieval-оценка 4 development + 9 открытых вопросов. Она не подключена к Evolution runner; прежний holdout после просмотра стал regression-набором
§8: полный авторский цикл	Есть Git candidate/checks/critic backend, короткий model-authored probe и реальные HTTP MCP вызовы	Полный native author task ранее завершился 422; успешный полный proposal→checks→critic на реальном eval не подтверждён. Аналитические UI-вызовы этого не заменяют
§8: human release, bundle, manifest, rollback	Не реализованы; release_available=false, MCP намеренно не даёт release	Нужна отдельная операторская команда, точные версии/approval, атомарная активация и проверенный rollback. Без неё улучшение не поступает в serving
§8: fault recovery/idempotency jobs	Proposal/checks/verdict сохраняются, есть lock и повторное чтение	Нет испытаний crash между commit/ref и сохранением state, model timeout с неизвестным usage, release interruption. Review при недоступности можно повторить; это не строгая идемпотентность удалённого LLM-вызова
§9: OS isolation, trusted evaluator, secret boundaries	Разные процессы/токены есть, отдельного OS/container author sandbox нет	Native checkout/env очищены, CLI ограничивает tools; это не доказанная изоляция UI worker. Holdout не отделён от автора правами ОС
§9: budgets и остановка	Есть model timeout, disabled retries и native round/time settings; нет общего request budget/cost reservation	Лимиты LLM/tool calls, всего input tokens, wall-time graph, price config и гарантированный partial по исчерпанию не реализованы. Native cost settings без подтверждённого тарифа GigaChat не дают денежной гарантии
§9: logs/trace/replay/retention	Core возвращает request_id, usage, evidence; native пишет свои логи	Нет единого сохранённого trace/feedback, timings, release/model/corpus versions и retention/replay контракта core
§10–11: комплексная оценка	103 unit/integration теста и узкие live evidence не равны 25–30 размеченным end-to-end случаям	Нужны report/web/hybrid/comparison/scenario/out-of-scope/injection/outage, финальная атрибуция UI, latency/usage и результаты по случаям
§12: понятный код около 3000 строк	2575 строк src/scripts + 1188 тестов = 3763, обычное форматирование	Ориентир превышен на 763 строки. Пользователь сказал «желательно»; это не жёсткий отказ и не повод скрывать код или удалять важные проверки

Изменения, которые **не следует считать недоделками**: native UI вместо Streamlit согласован; DDGS вместо Tavily допустим заданием; один фиксированный ARIMA order вместо перебора допустим; минимум 96 месяцев вместо

ранней гипотезы 60 объясняется calibration/test; default top-k=4 и chunk=400 — параметры реализации. Запрет default output cap задан пользователем позже: LLM_MAX_OUTPUT_TOKENS=None сохраняется и тестируется. Табличные ограничения, отсутствие OCR и отсутствие торговли — заявленные границы, не скрытые функции.

4. Подтверждённые сильные части

- Два независимых Git и MCP, разные bearer credentials, protected policy schema, idempotent proposal и сохранение candidate main отдельно; auth и unsafe reject проверены.

- Реальный OPEC/EIA корпус: 154 PDF-страницы, 475 E5/Chroma фрагментов. Есть живой ответ EIA с проверенной PDF-цитатой.

- Реальные ARIMA/ETS, отдельные calibration и rolling test по h=1..6, naive comparison, 80% интервалы, контроль данных и отсутствие влияния будущих наблюдений в проверенном сценарии.

- MCP start_date/end_date; кеш скачивает только непокрытые интервалы, не перезаписывает сохранённые цены. Реальный HTTP MCP прогон с FRED/EIA подтвердил extended → hit без LLM. Сбои/пробелы покрыты offline-тестами.

- GigaChat live structured calls и самостоятельный выбор forecast подтверждены. OpenAI/local adapter есть, optional output limit сохраняется как None по умолчанию.

- Native UI проверен настоящим браузером на report/forecast, skill прошёл штатный review exact bytes. Известная ошибка финального пересказа сохранена, не объявлена успешной приёмкой.

Ссылки: RAG, retrieval eval, web, forecast, кеш, native UI, интеграция.

5. Приоритет закрытия

1. **Поведение из DOCX:** объединить report+web, реализовать scenario с явными inputs, исправить атрибуцию источника в финальном UI. Проверить успешный web-ответ и честное поведение при outage/current quote unavailable.

2. **Сдаваемый результат:** пять настоящих диалогов, итоговый короткий отчёт и README с обоснованием модели; clean installation и запуск всей поставки одной командой, затем Linux/Docker проверка и подтверждённый URL репозитория.

3. **Согласованное самоулучшение:** подключить policy к реальному retrieval, paired fixed eval с новым закрытым набором, затем полный author/check/critic и операторский release/rollback. До этого называть механизм кандидатов прототипом, а не доказанным улучшением аналитика.

4. **Остальные обещания архитектуры:** core memory/follow-up, сравнения, typed claims/repair, budgets, isolation, traces и оценка. При недельном сроке явно зафиксировать, какие остаются ограничениями; не выдавать их за требования DOCX или уже реализованные функции.

Для экономии квоты сначала deterministic/offline проверки, затем несколько выбранных live-запросов. Этот порядок — рекомендация аудита, не начало реализации и не разрешение публиковать/развёртывать проект.

6. Привязки к коду

- web заменяет evidence, scenario-заглушка, свежие запросы пропускают RAG, core без session contract.

- контракты Route/Claim, верификация цитат/чисел, retrieval без Evolution policy.

- синтетические checks, critic, реальная отдельная retrieval-оценка.

- MCP-контракты, cache, forecast, compose.

OilAgent: actual components and remaining gaps

Audit of core b1d2fa5 / evolution 4b829d0 | 2026-11-01

